


講義・ハンズオン

AI/BIワークショップ

Databricksデータインテリジェンスプラットフォーム



Agenda

1. Unity Catalog & AI/BI 概要説明 (15分)

2. ハンズオン (85分)

- Unity Catalog (15分)
- AI/BI ダッシュボード (35分)
- AI/BI Genie (35分)



Q. データガバナンスとは？

A. データ資産について、ライフサイクル全体を通して管理するための、
原則、プラクティス(実践的な手法)、ツールを組み合わせた総合的な管理手法

事実

- デジタルビジネスを拡大しようとする組織の80%は、不十分なガバナンスが原因で失敗している([Gartner](#))
- データガバナンスの不備により、ユーザーの時間の30%が付加価値のないタスクに費やされている([McKinsey](#))
- データガバナンスの不備は、年間1,500万ドルもの財務的損失をもたらす可能性がある([investopedia](#))

主要なテーマ

アクセス制御

データ保護の仕組み・方法

監査

データの使用状況の把握(利用者、時期)

ディスカバリー

データの容易な検索・検出

リネージ

データの関連性とライフサイクルの追跡

共有


社内外へのデータの安全な共有



Unity Catalog

データとAIを一元管理する
ガバナンス基盤

あらゆる外部
データソースと接続



あらゆるツール、エンジン、プ
ラットフォームとの
オープンなアクセスと連携



カタログエクスプローラー

データについての詳細を調べることができるポータルとして機能

テーブル構造・説明

列名、データ型、
ビジネスメタデータ等

その他基本情報

作成/最終更新の日時、ユーザー、ストレージの場所、
テーブルプロパティ等

アクセス権限

アクセスできるユーザーや権限の種類

履歴

いつ、誰が、どのコードやジョブでどんな処理をしたか、等を
一覧表示

カタログエクスプローラー > japan_execforum > bricksmart >

japan_execforum.bricksmart.gold_user ☆

概要 サンプルデータ 詳細 権限 履歴 依存関係 洞察 品質

Q 列をフィルタリング

AI生成

列	タイプ	コメント	タグ	列マスキールール
user_id	bigint	整数、ユニーク（主キー）	+	✎
name	string	文字列	+	✎
age	double	整数、0以上	+	✎
gender	string	文字列、'男性'、'女性'、'その他'	+	✎
email	string	文字列、メールアドレス	+	✎
registration_d...	date	日付、YYYY-MM-DD フォーマット	+	✎
region	string	文字列、例: '東京'、'大阪'、'北海道'	+	✎

データリネージュ

他のデータとの依存関係の可視化、ジョブやMLモデル、
コードとの関連も表示

データプロファイル


データの中身に関する様々な統計、データ品質のダッシュボード

利用状況

このテーブルを使用している
主なユーザー、クエリやコード、
利用頻度等を可視化




Databricksデータインテリジェンスプラットフォーム




Databricks AI/BI

インテリジェントな
分析をあらゆる人に



ダッシュボード

組織全体に対して
迅速かつ安全に
視覚的な洞察を提供



Genie

自然言語を使って
データと会話

Unity Catalogによるガバナンス

AI/BI ダッシュボード

データを可視化

一般提供(GA)

AI支援によるBI開発

自然言語を用いて、データセット、
ビジュアル、ダッシュボードを
素早く作成

統合されたガバナンスと セキュリティ

生データからダッシュボードまで、
エンドツーエンドでリネージを追跡

リアルタイムのインサイト提供

従来のBIツールの様にデータの範囲や
鮮度を犠牲にせず、リアルタイムに
インサイトを提供

Sales Opportunity Overview

Deals created between

Mar 12, 2024 → Jun 12, 2024

Avg days to close

29.347

Avg probability of close

73.854

Avg active opp size

82.29K


Avg cust annual rev

246.78M

Percentage of opportunities by stage




Opportunity by market region size




Opportunity amount by customer annual revenue



AI支援によるデータ分析と可視化




自然言語を用いて ダッシュボードに
必要なデータセットを作成




自然言語と画面のクリックで
新しいビジュアルを作成



データとBIの統合的なガバナンスとセキュリティ



データとBI資産を一元的に管理・保護
Databricks外で特別なガバナンスモデルや
データウェアハウスを準備する必要なし



エンドツーエンド・列レベルのリネージ
データパイプラインの変更が
下流のダッシュボードにどんな影響を
与えるかを列レベルで把握




すべてのデータを用いて 超高速・インタラクティブ にインサイトを得る

あらゆる規模に対応する超高速で
インタラクティブなダッシュボード

すべてのデータを用いた分析
vs. 抽出データのみを用いた分析

常に最新のデータで
リアルタイムの分析 を構築・展開



売上とユーザー分析

起動 date (MMM DD, YYYY)

→ 終了 date (MMM DD, YYYY)



買上回数

116.29万


総売上

32.29億

ユーザー数

69.38億

売上のトレンド (日次)



地域別買上回数と平均オーダー単価の散布図



地域ごとの売上

閲覧と編集の分離

下書き

ダッシュボードのレイアウトを編集



公開済み

7月 03, 2024 10:30 午前

region: 東京 大阪 北海道 福岡 沖縄

地域ごとの買上回数

Count of Unique transaction_id



region: 東京 大阪 北海道 福岡 沖縄

ユーザーの年齢分布

6億



たしかに、良いダッシュボードは
多くの質問に答えてくれる



あなたが予測できるのは ユーザーが尋ねる質問のほんの一部

主要なサプライヤーは？

配送の遅延頻度は？

場所別の在庫の状況は？

最も利益が大きい製品は？

配送遅延のコストは？

配送コストの傾向は？

持続可能性目標の達成状況は？

現在の在庫レベルは？

ユニークユーザー数は？

最もリードタイムが長いサプライヤーは？

国別の売上の推移は？

サプライチェーンのボトルネックはどこか？

倉庫の稼働率は？


欠品が発生している製品は？

需要予測の精度は？

余剰在庫がある場所は？

平均的な注文履行時間は？

製品別の返品率は？



注文の優先度の変化の傾向は？

最もポピュラーな配送方法は？

最も重要な顧客層は？

品質に問題のあるサプライヤーは？

サプライヤーの契約義務の遵守状況は？

輸送コストの傾向は？

もし、ユーザーが
自分たちが持っているデータと
会話することができたら？



もし、ユーザーが
自分たちが持っているデータと
会話することができたら？



A Ali Ghodsi



ビジネスは年度の目標に対してどう進捗している？

Assistant

Certified answer

	製品ライン	売上実績	売上予測	差分	目標
1	Apparel	\$13,284,589.34	\$12,300,000	8.00%	\$30,430,000
2	Home Goods	\$7,589,320.38	\$7,950,000	-4.54%	\$11,200,000
3	Toys and Games	\$6,100,382.94	\$6,100,000	0.01%	\$9,000,000
4	Electronics	\$2,596,001.27	\$2,150,500	20.72%	\$4,050,000
5	Books and Music	\$552,926.81	\$1,300,000	-57.47%	\$3,900,500



AI/BI Genie

データと会話

一般提供 (GA)

セルフサービスでの Q&A


ダッシュボードの更に先へ: ユーザーが自らのデータと自然言語を通じて会話しインサイトを得られる

データインテリジェンスを活用した AI

AIはユーザーデータに固有の知識を元に回答、ユーザーフィードバックを通じた精度の向上が可能

ガバナンスとセキュリティ

ユーザーがアクセス可能なデータは Unity Catalog で完全に管理



質問は何でしょうか？




AIエージェント

GENIE



ユーザーデータの意味を
継続的に理解



ユーザー固有のデータの 意味を継続的に学習する エージェントシステム

専門のAIエージェントが協調して動作するアンサンブル方式

ツールとコンテキストの活用


- Unity Catalogのメタデータ
- クエリ履歴 (すべてのワークロード)
- 関連する資産 (ノートブック、ダッシュボード、クエリ)
- セマンティックモデル (利用可能な場合)

必要に応じてユーザーに確認を求める

学習し、記憶する



ダッシュボードの更に先へ




自社が持つデータに直接、
対話型のQ&Aを行う

Genieが会話のスレッドを保存、
前回の続きから再開できる

Genieは自然言語、表形式、
グラフを使って回答



データインテリジェンス を活用した AIによる精度の高い回答



データプラットフォーム からのインテリジェンス

GenieはUnity Catalogのテーブルのスキーマ、コメント、PK/FK関係を理解する。加えて、ダッシュボード内のSQLクエリも理解する。

The image shows a chat interface with a sidebar containing icons for chat, documents, tables, charts, and settings. The main area displays 'Example SQL Queries' with a list of queries and their explanations. The queries include: 'Churned customers are all the customers that generated sales in a particular month, but did not generate any sales in the following month.', 'Show me average price by model', and 'how many customers churned in january 2024?'. Each query is followed by its SQL code.

管理者の指示を通じた インテリジェンス

Genieスペースの管理者は、指示(例:SQLクエリ、ビジネスルール、セマンティクス)を通じて更にインテリジェンスを追加できる。


The image shows a chat interface with a sidebar containing icons for chat, documents, tables, charts, and settings. The main area displays a conversation between 'Richard Tomlinson' and 'Genie'. Richard asks: 'Churned customers are all the customers that generated sales in a particular month, but did not generate any sales in the following month.' Genie responds: 'This query calculates the number of churned customers in each territory based on their monthly sales activity. It first identifies churned customers by comparing their activity in consecutive months, and then counts the churned customers in each territory.' Below the response is a table with columns 'Employee_Territory' and 'churned_customers'.

ユーザーフィードバックを 通じたインテリジェンス

質問にどのように回答すべきか不確かな場合、Genieは回答を推測するのではなくユーザーに明確化を求める。ユーザーはリアルタイムでフィードバックを提供することで、Genieの回答精度を更に向上できる。




AIが生成するインサイトに ガバナンスとセキュリティを適用



Status	Question	Rating	User	Created
Completed	what are all my opportunities that started in december fy 2023?		Hanlin Sun	2024-05-28 15:4...
Completed	what about just in December FY 2023?		Hanlin Sun	2024-05-28 15:3...
Completed	which sales reps converted open opportunities to closed opportunities at the highest percentage?		Hanlin Sun	2024-05-28 15:3...
Completed	which quarter in 2023 saw the most opportunities go from open to won?		Hanlin Sun	2024-05-28 15:3...
Completed	what were the biggest closed deals in 2023 and who were the sales reps for them?		Hanlin Sun	2024-05-28 15:2...
Completed	what were the biggest closed deals in 2023 and who were the sales reps for them?		Hanlin Sun	2024-05-28 15:1...
Completed	What is the expected value of all open opportunities in Dec 2023?		Hanlin Sun	2024-05-28 15:1...
Completed	wghat is the most recent sales opportunity?		Hanlin Sun	2024-05-28 15:0...
Completed	what is the average?		Hanlin Sun	2024-05-28 14:5...
Completed	what is the smallest?		Hanlin Sun	2024-05-28 14:5...
Completed	what is thee biggest sales opportunity I've ever had?		Hanlin Sun	2024-05-28 14:5...
Completed	What is the expected value of all open opportunities in Dec 2023?		chao.cai@databricks.com	2024-05-28 14:1...
Completed	What is the expected value of all open opportunities in Jan 2024?		chao.cai@databricks.com	2024-05-28 14:1...
Completed	when was the first opportunity that was not closed won or lost?		chao.cai@databricks.com	2024-05-28 13:5...
Completed	when was the latest opportunity that was closed won or lost?		chao.cai@databricks.com	2024-05-28 13:5...

Genieのモニタリング機能を用いることで、ユーザーが質問した内容をレビューできる。評価(良い/悪い)を元に今後の回答精度を向上させられる。



GenieはUnity Catalogのアクセスポリシーを遵守し、ユーザーがアクセス可能なデータのみを返却する。



Genie Conversation APIs

AI/BI Genieスペースとプログラムを通じてやりとりが可能に



組織全体であらゆる場所からデータ
と会話が可能に – Teams, Slack,
Sharepoint, Confluence,
Databricks Appsなど！

その場で質問が可能、コンテキスト
の切り替えが不要

Mosai AIエージェントフレームワーク
内でGenieをtext2sqlエージェントと
して活用可能


Public Preview

The image displays two screenshots of the Genie Conversation APIs documentation. The left screenshot shows the 'Start conversation' endpoint, which is a POST request to `/api/2.0/genie/spaces/{space_id}/start-conversation`. It includes a 'Request body' with a 'content' string (e.g., 'Biggest open opportunities') and a 'Responses' section showing a successful 200 status. The right screenshot shows the 'Execute SQL query in a conversation message' endpoint, which is a POST request to `/api/2.0/genie/spaces/{space_id}/conversations/{conversation_id}/messages/{message_id}/execute-query`. It includes 'Path parameters' for 'space_id', 'conversation_id', and 'message_id', and a 'Responses' section showing a successful 200 status and a JSON response structure for the SQL query execution.



AI/BIを選ぶ理由

1



シンプルなアーキテクチャー

AI/BIはデータプラットフォームの一部として統合されているため、別のデータシステムやBIシステムの管理は不要

2



データを深く理解

AI/BIはユーザーのデータ資産や使用パターン、ビジネスの概念に関する深い知識を持ち、関連性が高く正確な回答を迅速に生成

3



より賢いセルフサービス

AI/BI Genieは、ビジネスユーザーがダッシュボードを超えて、自然言語を使って新しいインサイトをセルフサービスで得られるようサポートする

